

ARCHITECTURES AND AI MODERATION STRATEGIES FOR MULTI-PARTY SPEECH CONVERSATIONAL SYSTEMS

Salvatore Conte

Prof. Franca Garzotto

Tutor Pietro Ammaturo

Politecnico di Milano-2026

Gap di ricerca emersi dallo stato dell'arte

GAP 1

I sistemi vocali sono quasi sempre dyadic

- I sistemi conversazionali vocali sono progettati per 1 utente ↔ 1 agente
- I sistemi multiparty esistenti sono quasi tutti text-based (chat, forum, Slack)
- I pochissimi sistemi multiparty + speech (ARI, Furhat) supportano solo 2 umani + 1 robot e dipendono da gaze/video

GAP 2

I sistemi multiparty esistenti sono quasi tutti text-based

	Dyadic	Multiparty
Text-based	Chatbot, ChatGPT	Koala, Slack, forum
Speech-based	Moshi, GPT-4, Alexa, Siri	<u>Alutami</u>

Gap di ricerca emersi dallo stato dell'arte

GAP 3

Mancano architetture progettate per multiparty speech

Le architetture vocali attuali (pipeline STT→LLM→TTS, half-cascade, end-to-end) assumono un singolo parlante ↔ un singolo agente

Nel multiparty servono :

- Gestione di N stream audio in parallelo
 - Turn-taking tra N partecipanti
 - Decidere quando e a chi rispondere

GAP 4

Il ruolo dell'AI come moderatore di gruppo è poco studiato

- La maggior parte dei conversational agents agisce come assistente, sistema di risposta, supporto informativo
 - Pochissimi lavori studiano l'AI nel ruolo di moderatore della conversazione
- Nessuno studia un AI moderatore vocale che in tempo reale:
 - Gestisca il turn-taking
 - Bilanci la partecipazione
 - Guidi la discussione senza suggerire risposte

Direzione di tesi

Titolo principale:

Architectures and AI Moderation Strategies for Multi-Party Speech Conversational Systems

1. Architettura per multiparty speech con AI moderatore

- Gestione di N stream audio
- Turn-taking esplicito tra N partecipanti
- Pipeline STT → LLM → TTS con ASR gating
- Design modulare: sessions, turns, ASR, moderation, WebRTC

2. Strategie di moderazione AI

- Quando intervenire (fine turno, silenzio, sbilanciamento)
 - Come intervenire (sintetizzare, rilanciare, coinvolgere chi non parla)
- Prompt engineering per il ruolo di moderatore

3. Valutazione empirica →


Valutazione empirica

Proposta A: Murder Mystery

- Task: 3 partecipanti ricevono versioni diverse di un caso poliziesco, solo combinando gli indizi critici si trova il colpevole
 - Confronto qualitativo con tesi Dubini (2024) — stessa task, ma moderazione **testuale** → **vocale**
 - Design: single-condition (tutti con moderatore AI vocale), poi confronto con risultati Dubini
- Metriche: correct culprit, critical clues, Gini index, discussion focus + SUS, UX
- Partecipanti: **30-36 volontari**, 10-12 gruppi da 3
- Durata sessione: ~**75 min** (30m reading, 30m moderation, 15 questionari)

Limiti:

- Confronto "sporco" (cambiano modalità, piattaforma, partecipanti)
- Sessioni lunghe → difficile reclutare volontari non pagati
- Metrica principale binaria (giusto/sbagliato) → basso potere statistico



Valutazione empirica

Proposta B: Desert Survival Problem

Task: incidente nel deserto, classificare 15 oggetti per sopravvivenza.

Esiste ranking esperto → metrica oggettiva continua.

Varianti equivalenti in letteratura: Arctic Survival, NASA Moon Survival (stessa struttura, stessi autori, usate in combinazione negli studi within-subjects).

Procedura (~40 min per sessione):

- 1. Briefing + consenso (5 min)
- 2. Lettura scenario + ranking individuale (5 min)
- 3. Discussione vocale su Alutami (20 min) → ranking di gruppo
- 4. Questionari UX (10 min)

→ Confronto: ranking individuale vs ranking gruppo vs ranking esperto = decision accuracy + synergy score

2 proposte di design

	B1 — Between-subjects	B2 — Within-subjects
Setup	5 gruppi con, 5 senza moderatore. Tutti fanno Desert	Ordine controbilanciato: metà dei gruppi inizia con moderatore, metà senza (poi si invertono)
Partecipanti	30 persone, 10 gruppi	30 persone, 10 gruppi
Durata	~40 min (1 sessione)	~80 min (2 sessioni)
Vantaggio	Sessione singola	Ogni gruppo proprio controllo-> piu potere statistico, elimina variabilità gruppi

Perchè scegliere Desert Survival

	<i>Murder Mistery</i>	Desert Survival
Lettura materiali	30 min, decide di indizi da memorizzare- pesante per volontari non pagati	5 min – un foglio A4 con scenario e lista oggetti
Reclutamento	Difficile, sessione lunga, Dubini con Prolific (pagati) aveva già problemi di qualità	Realistico – sessione corta, basso carico cognitivo iniziale
Tipo di metrica	Binaria (colpevole giusto/sbagliato) → basso potere statistico	Continua (distanza dal ranking esperto) → più potere statistico
Design sperimentale	Single condition, confronto ‘sporco’ con Dubini (cambiano modalità, piattaforma, partecipanti)	Confronto pulito moderatore ON vs OFF, stessa piattaforma, unica variabile

Il Survival Task in letteratura

Il survival ranking task è uno dei paradigmi sperimentali più consolidati nello studio del group decision-making. Il task originale, il **Desert Survival Problem**, è stato sviluppato da Lafferty e Eady nel 1974: i partecipanti devono classificare 15 oggetti in ordine di utilità per la sopravvivenza dopo un incidente aereo nel deserto del Sonora. Esiste un ranking corretto definito da esperti di sopravvivenza, che fornisce una metrica oggettiva e continua per valutare la qualità della decisione. Fa parte di una famiglia di varianti equivalenti — Arctic Survival, NASA Moon Survival — usate in combinazione per studi within-subjects.

Il paradigma è stato introdotto nella ricerca da **Hall e Watson nel 1970**, che utilizzano il NASA Moon Survival per studiare l'effetto di istruzioni procedurali sulle decisioni di gruppo. I gruppi che ricevono istruzioni di consenso — cercare le differenze di opinione, evitare il voto a maggioranza — prendono decisioni significativamente migliori e raggiungono strong synergy, ovvero il gruppo batte il suo membro migliore, a tassi più alti rispetto ai gruppi in free discussion. Questo studio, con oltre 321 citazioni, stabilisce il paradigma sperimentale usato da tutta la letteratura successiva.

Hamada, Nakayama e Saiki nel 2020 utilizzano il NASA Moon Survival con 119 partecipanti organizzati in 25 gruppi. Confermano che i gruppi battono gli individui, con un errore medio di 36.88 rispetto a 46.99. Tuttavia trovano un risultato interessante: la discussione di gruppo libera, senza guida, non supera significativamente l'aggregazione statistica dei ranking individuali. Questo suggerisce che il semplice discutere non basta per sfruttare il potenziale del gruppo — serve una guida al processo deliberativo.

Infine, **Hémon, Cherbonnier, Michinov, Jamet e Michinov nel 2024** utilizzano proprio il Desert Survival Problem con 125 partecipanti che collaborano tramite videoconferenza. I gruppi che ricevono istruzioni basate sulla constructive controversy raggiungono strong synergy a tassi significativamente più alti rispetto ai gruppi in free discussion, e riportano maggiore epistemic conflict regulation. Questo paper è particolarmente rilevante perché dimostra due cose: che il Desert Survival funziona in setting online e in videoconferenza, e che guidare il processo deliberativo migliora la sinergia di gruppo — esattamente ciò che il moderatore AI di Alutami fa in tempo reale durante la discussione.